

# Segmentação e classificação de imagens mamográficas

Lucas Saliba<sup>1</sup>, Ygor Matheus Lacerda de Melo<sup>2</sup>

<sup>1</sup>Instituto de Ciências Exatas e Informática

Pontifícia Universidade Católica de Minas Gerais (PUC Minas)

Av. Dom José Gaspar, 500 – 30.535-610 – Belo Horizonte – MG – Brazil

## 1. Introdução

O câncer de mama é uma das doenças mais prevalentes entre mulheres em todo o mundo, superando o câncer de pulmão em número de casos, de acordo com a Organização Mundial da Saúde (OMS) em 2020. A densidade mamária pode ser um indicador de risco para o desenvolvimento do câncer de mama, pois mulheres com maior densidade podem ter lesões ocultas que podem ser indicativas da doença. Infelizmente, essas lesões geralmente são descobertas tardiamente, resultando em um agravamento do problema. Portanto, é crucial detectar o câncer o mais cedo possível, pois isso aumenta significativamente as chances de cura.

A densidade da mama está diretamente relacionada ao risco de desenvolvimento do câncer. Mulheres com maior densidade mamária podem ter lesões que passam despercebidas, levando a um diagnóstico tardio da doença. O American College of Radiology desenvolveu uma escala de densidade chamada BIRADS, que fornece informações aos radiologistas sobre a diminuição da sensibilidade dos exames à medida que a densidade da mama aumenta.

A motivação deste trabalho é realizar uma análise visual das imagens disponíveis resultantes de exames de mamografia, que é a principal ferramenta de rastreamento do câncer de mama. É essencial que a densidade mamária seja levada em consideração durante a avaliação, a fim de garantir uma detecção precoce e um tratamento adequado para o câncer de mama.

O objetivo deste trabalho é o desenvolvimento de um software que seja capaz de treinar uma rede neural através de imagens mamográficas a fim de ser capaz de realizar a classificação da imagem por tipo de BIRADS. Para obtermos um resultado satisfatório, é necessário a alta precisão de detecção da rede neural, diminuindo as taxas de erro e aumentando as taxas de acerto.

O restante deste artigo está organizado da seguinte forma: a Seção 2 trata da descrição de implementação do software e informações de bibliotecas utilizadas; a Seção 3 lista as técnicas implementadas para realização da classificação e método de segmentação das imagens; a Seção 4 discute os resultados obtidos; a Seção 6 mostra o relatório do Github e, por fim, a Seção 5 as referências bibliográficas.

## 2. Descrição do Projeto

O projeto foi desenvolvido utilizando a linguagem Python (versão 3.10.2 disponível para download no site oficial) e o Visual Studio Code como IDE. A seguir, forneceremos uma breve descrição sobre as bibliotecas aplicadas em nosso projeto.

## 2.1. Bibliotecas utilizadas

A biblioteca 'Tkinter' é uma biblioteca que já vem com a instalação do Python, utilizamos na criação da interface e importamos a função "filedialog". Para auxiliar no processamento das imagens e execução de tarefas de visão computacional, utilizamos a biblioteca 'CV2' do OpenCv, além da função "ImageTk" da biblioteca 'Pillow' que realiza a junção das bibliotecas 'Pillow' e 'Tkinter'. A biblioteca 'Numpy' também foi importada para auxiliar na manipulação das imagens. Já a biblioteca 'OS', é um módulo que auxilia na criação de scripts e a biblioteca 'TQDM' utilizamos para adicionar barras de progresso.

```
import cv2
import PIL
import PIL.ImageTk
import tkinter
import tkinter.filedialog
import os
import time
import tqdm
import numpy as np
import tensorflow as tf

from sklearn.metrics import confusion_matrix
from seaborn import heatmap

import matplotlib
```

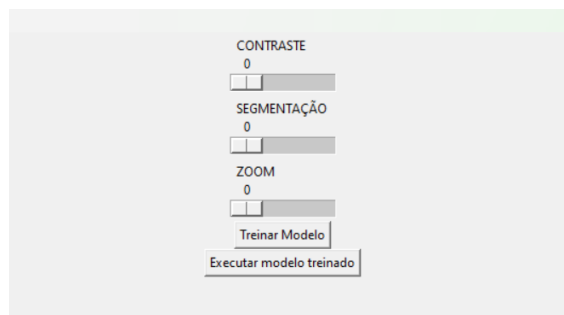
**Figura 1. Bibliotecas utilizadas no desenvolvimento da aplicação**

A biblioteca 'Time' tem o objetivo de medir o tempo de execução do treinamento e da classificação da rede neural. Se tratando da classificação, esta medição é utilizada tanto para medir o tempo de execução da classificação da imagem completa quanto da classificação de uma região específica selecionada pelo usuário. Utilizamos a função Keras da biblioteca de rede 'TensorFlow', voltada para o aprendizado de máquina, com o objetivo de criar e treinar a rede neural para detectar os padrões e classificar as imagens no tipo de BIRADS pertencente. Por fim, a biblioteca 'Mathplotlib' utilizamos para a matriz de confusão.

## 3. Técnicas Implementadas

Ao iniciar o software, deve-se selecionar a imagem para ser carregada no projeto, é permitido apenas a leitura de imagens no formato PNG e TIFF. Após realizar a abertura da imagem, é permitido ao usuário que aplique zoom, altere o contraste e realize a segmentação através de uma barra deslizante selecionando o valor de tons de cinza correspondente.

No diretório 'mamografia' estão presentes as imagens utilizadas para realizar o treinamento dos classificadores de BIRADS da nossa rede neural. Realizamos a leitura da base através da função 'read\_data', separando as imagens de treino e de teste. Ao realizamos a leitura de cada imagem, a função 'flip\_data' realiza o espelhamento e a função 'equalize\_data' a equalização do seu histograma, logo, para cada imagem, é gerado 4 variações: original e espelhada X original e equalizada.



**Figura 2. Janela de visualização ao iniciar o software**

Ao realizar a leitura das imagens, a função 'apply\_threshold' aplica a segmentação binária de forma automática nas mesmas, transformando os elementos de fundo e anotações com valor preto e a imagem da mama de branco.

```

167 # Segmentacao automatica de imagens do diretorio
168 def apply_threshold(X_array: list) -> list:
169     X_transformed = []
170     for X in X_array:
171         # Aplicacao de segmentacao binaria em cada item recebido
172         X_transformed.append(cv2.threshold(X, 7, 255, cv2.THRESH_BINARY)[1])
173
174     return X_transformed
175

```

**Figura 3. Função apply\_threshold que realiza a segmentação**

Na função da segmentação binária acima, inicialmente testamos o valor do kernel igual a 15, porém a região de dentro da mama ainda possuía algumas variações de tons de cinza, impossibilitando uma identificação com clareza. Ao realizar testes, definidos que o melhor valor para o kernel é defini-lo igual a 7, gerando a segmentação da imagem com menos ruído e melhor contorno das mamas.

Realizamos o aumento de dados das imagens de treino via espelhamento e equalização de histogramas salvando no mesmo array (x\_train) a fim de ter uma melhor praticidade e facilidade nos testes.

Na tentativa de implementar a rede neural ConvNext nos deparamos com algumas dificuldades e problemas de compatibilidade com nosso dataset. A princípio, tentamos usar ela com o Hugging Face porém não conseguimos pois ele já trabalha com um tipo de dataset deles mesmo, seguindo um diferente padrão.

A ConvNext foi pré-treinada com imagens padrão de 224x224 pixels e por conta disso a sua arquitetura já estava projetada para isso. Mesmo tentando fazer um resize de nossas imagens, estávamos tendo um problema com a classificação. Ao tentar usar a ConvNext do Keras, se limitarmos o número de classes para 4, diferente da original da ConvNext que é 1000, não podíamos alterar a primeira camada da rede e pelo visto isso estava dando algum problema no shape dos dados, a forma em que eles estavam entrando. Ou seja, se alterasse a primeira camada não poderíamos mexer no número de classes, estando isso escrito na documentação do Keras, assim não sendo possível treinar com nosso dataset com a quantidade de classes que gostaríamos.

```

# Aplicacao da rede neural ConvNext
def conv_next(X_train: np.array, X_test: np.array, y_train: np.array, y_test: np.array) -> None:
    model = tf.keras.applications.ConvNextBase(
        model_name="convnext_base",
        include_top=False,
        include_preprocessing=False,
        weights=None,
        input_tensor=tf.keras.layers.Input(shape=(224, 224, 1)),
        input_shape=None,
        pooling=None,
        classes=4,
        classifier_activation="softmax"
    )

    print('convnext')

    model.compile(loss="categorical_crossentropy", optimizer="adam", metrics=["accuracy"])

    print('compile')

    model.fit(X_train, y_train, verbose=1)

    print('fit')

```

**Figura 4. Implementação da rede neural ConvNext**

Após as tentativas da implementação da rede ConvNext, optamos pela implementação da rede neural convolucional, em que conseguimos realizar a classificação binária (I+II x III+IV) e a classificação de 4 classes (IxIIxIIIxIV). A imagem 5 mostra os diferentes hiperparâmetros utilizados.

```

# Modelo de rede neural convolucional
model = tf.keras.Sequential(
    [
        tf.keras.Input(shape=(194, 194, 1)),
        tf.keras.layers.Conv2D(64, kernel_size=(3, 3), activation="relu"),
        tf.keras.layers.MaxPooling2D(pool_size=(2, 2)),
        tf.keras.layers.Conv2D(512, kernel_size=(3, 3), activation="relu"),
        tf.keras.layers.MaxPooling2D(pool_size=(2, 2)),
        tf.keras.layers.Flatten(),
        tf.keras.layers.Dropout(0.5),
        tf.keras.layers.Dense(classes, activation="softmax")
    ]
)

```

**Figura 5. Implementação da rede neural convolucional**

Inicialmente, implementamos um modelo com três camadas contendo 32, 64 e 128 neurônios, respectivamente. Em seguida, realizamos uma ampliação para 64, 128 e 256 neurônios, mantendo as três camadas. Posteriormente, aumentamos para 128, 256 e 512 neurônios em cada camada, entretanto, notamos que não houve um avanço significativo na acurácia da classificação das quatro classes.

Percebemos que utilizando 3 camadas e aumentando a quantidade de neurônios, tínhamos um grande ganho na acurácia da classificação binária, porém a classificação de 4 classes estava sendo muito prejudicada. Além disso, começamos a enfrentar o risco de overfitting, onde o modelo estava se ajustando excessivamente aos dados de treinamento, prejudicando sua capacidade de generalização.

Como estratégia para superar essa limitação, decidimos reduzir uma camada ao modelo, com neurônios distribuídos nas quantidades de 128 e 256. Essa modificação nos trouxe o melhor resultado nos testes realizados, permitindo alcançar um desempenho mais eficiente na classificação das imagens. Percebemos que mesmo utilizando apenas 2 camadas, quanto mais aumentávamos os valores de seus neurônios melhor era a acurácia da

classificação binária e pior a de 4 classes. Ao rodar com 128 e 512 neurônios em cada camada respectivamente, obtivemos bons resultados, com ambos acima de uma acurácia de 55%. Entretanto, ao realizar os treinos vimos que os valores estavam muito instáveis, eles poderia ter uma grande variação ao executar o mesmo treino com os mesmos parâmetros.

Então realizamos a seguinte estratégia: removemos 15px de laterais da imagem, removendo bordas e ruídos indesejáveis e executamos a rede neural com 2 camadas com 64 e 512 neurônios cada. Assim, obtivemos bons resultados, ambos acima de 50% de acurácia e estáveis, passando mais segurança ao executar o dataset por completo. Com essa nova configuração de camadas e neurônios, conseguimos melhorar a capacidade de representação do modelo, resultando em uma maior precisão na classificação das quatro categorias do BIRADS.

### 3.1. Medidas

Para de iniciarmos a medição do tempo de execução do algoritmo, realizamos uma análise do custo na resolução do nosso problema, que consiste no treinamento e classificação de imagens. Com base nessa análise, teremos o número de vezes que cada etapa do algoritmo foi executada.

### 3.2. Descritores

No nosso projeto, utilizamos a matriz de confusão, na classificação das categorias de imagens de acordo com o BIRADS, ela irá nos ajudar a entender como o modelo está realizando a classificação para cada categoria. A matriz de confusão nos permite visualizar não apenas os acertos do modelo em cada categoria, mas também os erros de classificação.




Figura 6. Matriz de Confusão

### 3.3. Hiperparâmetros do classificador

O resultado obtido foi baseado em uma métrica que avalia a precisão do modelo, utilizando a acurácia e a perda (loss). Durante o processo de treinamento, foram utilizados

múltiplos "epochs", que representam os ciclos completos em que a rede neural percorre todos os dados de treinamento. A fim de otimizar o treinamento, definimos o tamanho do lote (batch size) da rede neural como 16, permitindo o processamento eficiente dos dados.

Nosso modelo foi projetado com duas camadas. A primeira camada possui 64 neurônios, a segunda camada contém 512 neurônios. Essa configuração de camadas e neurônios permite uma representação mais complexa e expressiva dos dados, melhorando o desempenho e a capacidade de aprendizado do modelo.

Além disso, utilizamos 1024 nós ou neurônios para testar as bases de dados. Essa escolha foi feita com o objetivo de garantir uma capacidade de processamento adequada para a análise dos dados e a obtenção dos melhores resultados. Ao combinar essa configuração com os hiperparâmetros ajustados durante o treinamento, conseguimos alcançar um desempenho otimizado e um modelo bem ajustado às características das bases de dados.

#### 4. Resultados obtidos

Ao realizarmos o treinamento e classificação da base de dados, levamos em consideração os critérios de precisão e eficiência de processamento. O tempo total para rodar a base de dados foi de **TODO: Adicionar tempo de execução final**.

Durante a execução do treinamento, é mostrado o tempo após cada medida do epoch

```
Epoch 1/2  
22/22 [=====] - 16s 705ms/step - loss: 1.8374 - accuracy: 0.6958 - precision: 0.6958 - recall: 0.6958 - specificity_at_sensitivity: 0.6870 - val_loss: 0.7971 - val_accuracy: 0.6256 - val_precision: 0.6256 - val_recall: 0.6256 - val_specificity_at_sensitivity: 0.0000e+00  
Epoch 2/2  
22/22 [=====] - 15s 699ms/step - loss: 0.5535 - accuracy: 0.7159 - precision: 0.7159 - recall: 0.7159 - specificity_at_sensitivity: 0.8609 - val_loss: 1.8872 - val_accuracy: 0.6769 - val_precision: 0.6769 - val_recall: 0.6769 - val_specificity_at_sensitivity: 0.0000e+00
```

**Figura 7. Visualização dos valores durante a execução de cada epoch**

Após o processo de treinamento, o algoritmo armazena o modelo encontrado em um arquivo chamado "conv". É exibido na janela de execução, os valores referentes a classificação binária e da classificação de 4 classes como mostrado na figura abaixo:

```
Binário (2 Classes):  
  
Loss: 1.8220  
Acurácia: 0.6562  
F1 Score: 0.6562  
Precisao: 0.6562  
Sensibilidade: 0.6562  
Especificidade: 0.8438  
Tempo: 192.65s  
  
4 Classes:  
  
Loss: 3.5462  
Acurácia: 0.5938  
F1 Score: 0.5614  
Precisao: 0.6400  
Sensibilidade: 0.5000  
Especificidade: 0.9271  
Tempo: 190.08s
```

**Figura 8. Visualização dos valores do processo de treinamento e classificação**

## 5. Referências Bibliográficas

A seguir, as referências que ajudaram o desenvolvimento do trabalho.

[https://www.tensorflow.org/api\\_docs](https://www.tensorflow.org/api_docs)

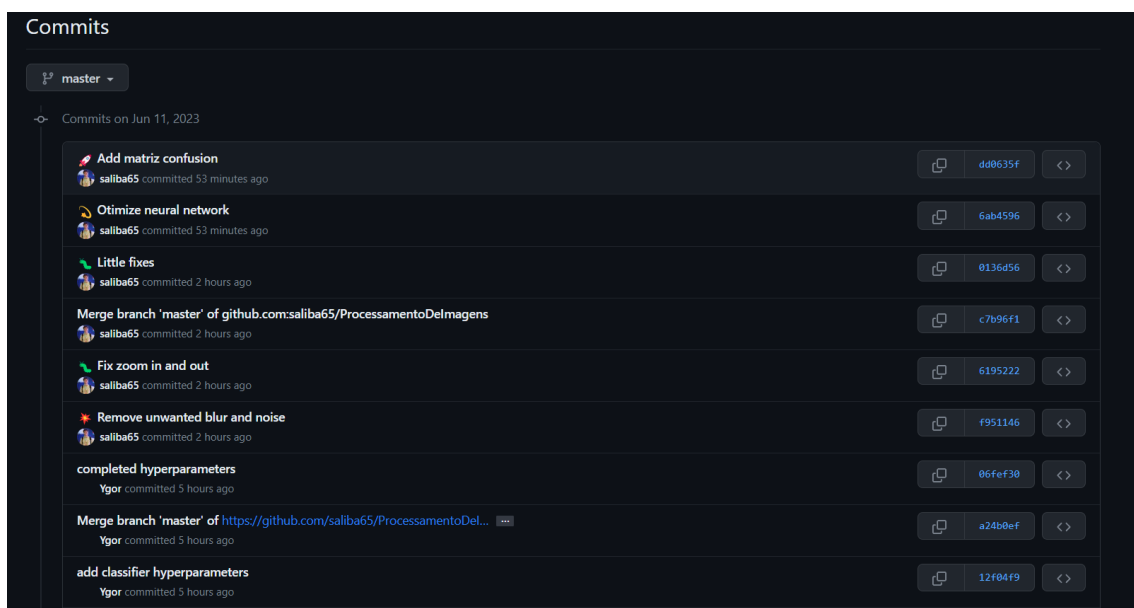
<https://docs.python.org/3/>

<https://docs.opencv.org/4.x/>

[https://huggingface.co/docs/transformers/model\\_doc/convnext](https://huggingface.co/docs/transformers/model_doc/convnext)

























<https://keras.io>

























## 6. Relatório de commits







The screenshot displays the 'Commits' page for a GitHub repository. At the top, there's a dropdown menu set to 'master'. Below it, a filter shows 'Commits on Jun 11, 2023'. The main area lists several commits, each with a title, author, time, and a commit hash. The commits are as follows:

Commit Title	Author	Time	Commit Hash
Add matriz confusion	saliba65	committed 53 minutes ago	dd0635f
Otimize neural network	saliba65	committed 53 minutes ago	6ab4596
Little fixes	saliba65	committed 2 hours ago	0136d56
Merge branch 'master' of github.com:saliba65/ProcessamentoDeImagens	saliba65	committed 2 hours ago	c7b96f1
Fix zoom in and out	saliba65	committed 2 hours ago	6195222
Remove unwanted blur and noise	saliba65	committed 2 hours ago	f951146
completed hyperparameters	Ygor	committed 5 hours ago	06feF30
Merge branch 'master' of https://github.com/saliba65/ProcessamentoDeImagens	Ygor	committed 5 hours ago	a24b0ef
add classifier hyperparameters	Ygor	committed 5 hours ago	12f04f9

adjustment of measurements Ygor committed 5 hours ago		3f87639	
Ajustando tecnicas descritas Ygor committed 5 hours ago		0918b32	
Merge branch 'master' of github.com:saliba65/ProcessamentoDelmagens saliba65 committed 5 hours ago		07155ad	
Try to implement convNext saliba65 committed 5 hours ago		5b7e141	
Merge branch 'master' of https://github.com/saliba65/ProcessamentoDel... Ygor committed 5 hours ago		bb1e9ee	
Adjusted imagens and segmentation Ygor committed 5 hours ago		1e9d177	
Merge branch 'master' of github.com:saliba65/ProcessamentoDelmagens saliba65 committed 5 hours ago		b8bcc6a	
Print results of functions saliba65 committed 5 hours ago		b007a43	
Create button for test only - save train model saliba65 committed 5 hours ago		c76fadd	
Implement confusion matrix saliba65 committed 6 hours ago		2db07d2	
Completed conclusion Ygor committed 7 hours ago		88ab981	
Add conclusion values Ygor committed 7 hours ago		12800c9	

Add hiperparametros do classificador Ygor committed 7 hours ago		0c287e4	
complementary result training Ygor committed 7 hours ago		eb23b28	
Add complementary descriptors Ygor committed 8 hours ago		5643e71	
Add descriptors Ygor committed 8 hours ago		1cd91e5	
Include time for algorithm Ygor committed 8 hours ago		ea10795	
Adjust segmentation Ygor committed 9 hours ago		3b4e2ac	
Techniques segmentation Ygor committed 10 hours ago		5b0549e	
Describing implementation techniques for segmentation Ygor committed 10 hours ago		2e4ce92	
Init add implemented TensorFlow for BIRADS Ygor committed 11 hours ago		51a76d9	
Completed libraries time and TensorFlow Ygor committed 11 hours ago		19a6315	
Merge branch 'master' of https://github.com/saliba65/ProcessamentoDel... Ygor committed 12 hours ago		6b33796	
Add libraries Ygor committed 12 hours ago		984613b	

Merge branch 'master' of github.com:saliba65/ProcessamentoDelmagens saliba65 committed 13 hours ago		7e2b848	
Improve neural network saliba65 committed 13 hours ago		d0c5606	



## Commits

🔍 master ▾

🔍 Commits on Jun 11, 2023

🔗 Try to implement ConvNext with tensorflow

saliba65 committed 13 hours ago

65ac356 <>

🔗 Completing introduction

Ygor committed 13 hours ago

d156214 <>

🔗 Add introduction article

Ygor committed 13 hours ago

ad27f98 <>

🔗 Article format setting

Ygor committed 13 hours ago

4fa9c04 <>

🔍 Commits on Jun 10, 2023

🔗 Get and print results

saliba65 committed yesterday

10c8cfe <>

🔗 Rede neural convolucional

saliba65 committed yesterday

abb6238 <>

🔗 Try implement ConvNext

saliba65 committed 2 days ago

684bc9e <>

🔗 Binary classification

saliba65 committed 2 days ago

a43c4ca <>

🔗 Fix equalize and flip images

saliba65 committed 2 days ago

f74e843 <>

🔍 Commits on Jun 9, 2023

⚡ Equalize histogram

saliba65 committed 2 days ago

fcd874a <>

🔗 Invert images matriz

saliba65 committed 2 days ago

5e38ab4 <>

🔗 Try read directory with button

saliba65 committed 2 days ago

15bc589 <>

🔍 Commits on Jun 6, 2023

🌱 Restructure folders

saliba65 committed 5 days ago

0333040 <>

🔗 Segmentacao automatica imagens diretorio

saliba65 committed 5 days ago

154d545 <>

🔗 Add git ignore

saliba65 committed 5 days ago

7137786 <>

🔗 Read directory files - testes e treinos

saliba65 committed 5 days ago

e6abd4f <>

🔗 Apply zoom function

saliba65 committed 5 days ago

d733315 <>

🌱 Refactor and organize code

saliba65 committed 5 days ago

1b60d4b <>

Commits on Jun 2, 2023

🌟 Image segmentation

saliba65 committed last week

📄

f63ec3f

<>

🌟 Implementing contrast bar

saliba65 committed last week

📄

409b116

<>

🔥 Remove useles files

saliba65 committed last week

📄

bbe73e0

<>

Merge branch 'master' of github.com:saliba65/ProcessamentoDeImagens

saliba65 committed last week

📄

bbb7a6e

<>

🔧 Refactor - using tkinter for read images

saliba65 committed last week

📄

c6e8eef

<>

Commits on Apr 24, 2023

Menu bar com o pyQT6

Ygor committed on Apr 24

📄

6c280a5

<>

Commits on Apr 18, 2023

Merge pull request #1 from saliba65/feature/create-interface

saliba65 committed on Apr 18

Verified

📄

c0af416

<>

🔧 Implementing inicial interface

saliba65 committed on Apr 18

📄

25ecc62

<>

Criação da interface inicial

Ygor committed on Apr 18

📄

a61808b

<>

Commits on Apr 17, 2023

🌟 First commit

saliba65 committed on Apr 17

📄

e638d11

<>