

Trabalho Prático

Segmentação e classificação de imagens mamográficas

Data de entrega: 16/04/2023 (primeira parte) e 11/06/2023 (trabalho completo) até às 23:00 pelo Canvas

Valor: 35 pontos (8+27)

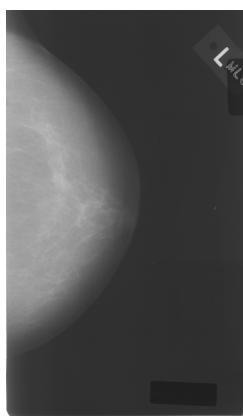
Penalidade por atraso: **Valor total, não se admite atraso!**

Grupos: 2 ou 3 componentes do mesmo campus. Os nomes dos componentes devem ser informados na planilha <https://docs.google.com/spreadsheets/d/13KB5RBTIDkkRt9an-vbLVvg3BaORwXKJFgJmDZ-Pds/edit?usp=sharing>

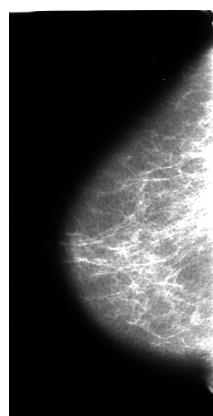
onde o grupo verá o nome do classificador a ser implementado. Não salte linhas da planilha nem edite o classificador. Escolha o próximo número de grupo disponível para o seu campus.

Descrição:

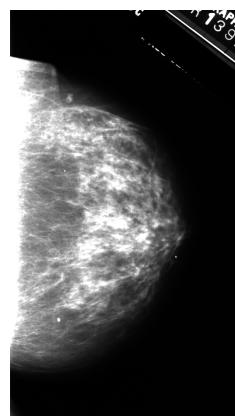
A densidade da mama é comprovadamente relacionada com o risco do desenvolvimento de câncer, uma vez que mulheres com uma maior densidade mamária podem esconder lesões, levando o câncer a ser detectado tarde. A escala de densidade chamada BIRADS foi desenvolvida pelo American College of Radiology e informa os radiologistas sobre a diminuição da sensibilidade do exame com o aumento da densidade da mama. BI-RADS definem a densidade como sendo quase inteiramente composta por gordura (densidade I), por tecido fibroglandular difuso (densidade II), por tecido denso heterogêneo (III) e por tecido extremamente denso (IV) (Fig.1). A mamografia é a principal ferramenta de rastreio do câncer e radiologistas avaliam a densidade da mama com base na análise visual das imagens



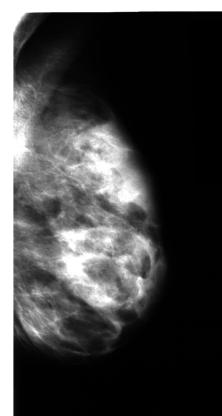
BIRADS I



BIRADS II



BIRADS III



BIRADS IV

Fig. 1. Exemplos de imagens das 4 classes BIRADS.

Neste trabalho, você deverá implementar um aplicativo que leia imagens de exames mamográficos, segmente a área da mama do fundo e possibilite o reconhecimento automático da densidade mamária. O dataset pode ser acessado no link a seguir (**Ver observação no fim deste documento**):
<https://www.dropbox.com/s/qt8afsmddppglahv/mamografias.zip?dl=0>

Especificações do programa:

- a) O programa deve ser implementado em C, C++, Python 3.8 ou Java, utilizando-se um repositório **privado** criado no Github. O relatório de commits deve se entregar junto com a documentação. Sugere-se também o uso do Google Colab.
- b) É permitido o uso de funções elementares de bibliotecas mas o código principal deve ser original. Por função elementar entende-se uma função básica de manipulação de imagens, cujo resultado não seja a solução final do problema. Ex: leitura de arquivos, cálculo de histogramas, filtros, cálculo de distâncias, conversão entre formatos de imagens, cálculo de características, classificadores de uso geral.
- c) Todo arquivo enviado deve conter o nome, matrícula, curso e campus dos componentes do grupo.
- d) O código deve ser comentado. Códigos não comentados perdem 30% dos pontos
- e) Códigos copiados anulam o trabalho.
- f) Qualquer drive montado em nuvem deve ser alterado para diretórios locais, de forma que seja possível executar os programas localmente.
- g) O ambiente deve ser totalmente gráfico e deverá oferecer as seguintes opções:

Primeira parte:

- Ler e visualizar imagens pelo menos nos formatos PNG e TIFF. As imagens podem ter qualquer resolução e número de tons de cinza (normalmente variando entre 8 e 16 bits por pixel);
- Exibir a imagem em uma janela, com opção de zoom;
- Oferecer opção para alteração de contraste por janelamento, com barras deslizantes para selecionar o valor mínimo e máximo da faixa de tons de cinza.

Segunda parte:

- Segmentar de forma automática a região da mama, colocando os elementos de fundo e anotações com valor preto (0). Aplicar a máscara de segmentação para eliminar os elementos de anotação e fundo de modo que a imagem a ser classificada tenha apenas a região da mama (Fig. 2).
- Ler os diretórios onde estarão as imagens usadas para treino e teste dos classificadores utilizados. As imagens com numeração múltiplo de 4 serão separadas para teste e as demais para treino. As classes de BIRADS I, II, III e IV começam com a letra D, E, F e G respectivamente. Existem imagens para a mama direita (right) e esquerda (left) tomadas nas orientações crânio-caudal (CC) e médio-lateral (MLO). O conjunto está

balanceado com 314 imagens em cada combinação de classe, mama e orientação, num total de 5024 imagens (1256 para teste e as demais para treino).

- Realizar aumento de dados **das imagens de treino** através de espelhamento horizontal e equalização de histogramas. Dessa forma, cada imagem gera 4 variações (espelhada e não espelhada X equalizada e não equalizada)

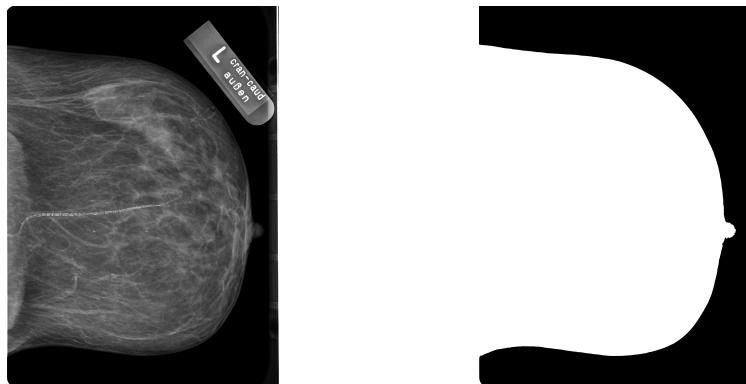


Fig. 2. Exemplo de imagem e máscara obtida na segmentação.

- Implementar a rede neural convolucional sorteada para o grupo. Utilize os pesos disponíveis no modelo, retreinando a parte completamente conectada com o dataset de treino. Após a convergência, salve o modelo com os pesos para não ter que retreinar na hora da apresentação. Treinar e classificar o conjunto de teste em 2 opções:
 - classificação binária (I+II x III+IV). O tempo de execução deve ser medido e exibido na interface, juntamente com as métricas de sensibilidade, especificidade, precisão, acurácia e escore F1.
 - classificação de 4 classes (I x II x III x IV). O tempo de execução deve ser medido e exibido na interface, juntamente com a matriz de confusão e as métricas de sensibilidade média e especificidade média. Para 4 classes e 314 imagens de teste por classe, teremos a matriz de confusão 4x4, M, onde a linha é a classe correta e a coluna a classe estimada. A sensibilidade média = acurácia = $\sum_{i=1..4} M_{i,i} / 1256$ e a especificidade = $1 - \sum_{i=1..4} \sum_{j \neq i} M_{j,i} / 3768$.

Opcional: Comparar os resultados de classificação baseados nas imagens originais e nas segmentadas. A segmentação e eliminação das anotações melhora a acurácia?

Considerações

- a) As imagens mostram a mama com tons mais claros e o fundo com tons mais escuros, na média.
- b) As anotações são mais claras que o fundo.
- c) A mama possui área maior que as anotações e sempre está anexada a pelo menos um lado da imagem.

- d) Podem haver regiões da imagem mais escuras que o fundo por terem sido apagadas para fim de anonimização (retirar elementos que identificam o paciente).

A documentação **EM FORMATO PDF** deve ser na forma de um artigo, contendo:

- a) A descrição do problema.
- b) Descrição das técnicas implementadas para a solução, principalmente dos classificadores e do método de segmentação.
- c) As referências das bibliotecas utilizadas.
- d) As medidas de tempo de execução para diversas imagens, descritores e hiperparâmetros do classificador.
- e) Resultados obtidos nos testes, gráficos de convergência, exemplos de erros e acertos dos métodos.
- h) Discussão dos resultados obtidos na segmentação.
- i) Discussão dos resultados obtidos nos classificadores, justificativa e análise de todos os hiperparâmetros e estratégias usados na concepção do classificador, incluindo o controle de overfitting, underfitting e velocidade de convergência. Incluir uma **figura** com a topologia da rede e uma **comparação** de resultados intermediários obtidos no processo de ajuste de hiperparâmetros. A nota será proporcional ao esforço empenhado no ajuste e **qualidade da análise**.
- j) Relatório do Github com os commits.
- f) Referências bibliográficas.

O que entregar:

Arquivos fontes e documentação. Coloque todos os arquivos na raiz de um diretório cujo nome deve ser o número de matrícula de um dos componentes. Comprima o diretório e poste no Canvas até a hora especificada para cada parte. O tamanho total dos arquivos não deve ultrapassar 5 Mbytes (não envie imagens nem o arquivo de pesos!).

Obs: Trabalhos de qualidade superior poderão ganhar pontos extras assim como o que obtiver as maiores taxas de acerto. **Não são permitidos o uso ou divulgação das imagens fornecidas, para outros fins, sem autorização prévia.**